

UniMetrocamp - Wyden

CAMPUS Campinas-SP

Campinas-SP, 2026

SENHAS EM RISCO: BIG DATA E SEGURANÇA DIGITAL

SUMÁRIO

DIAGNÓSTICO E TEORIZAÇÃO.....	4
Identificação das partes interessadas e parceiros.....	4
Problemática e/ou problemas identificados.....	4
Justificativa.....	4
Objetivos/resultados/efeitos a serem alcançados (em relação ao problema identificado e sob a perspectiva dos públicos envolvidos).....	5
Referencial teórico (subsídio teórico para propositura de ações da extensão).....	5
PLANEJAMENTO E DESENVOLVIMENTO DO PROJETO.....	6
Grupo de trabalho (descrição da responsabilidade de cada membro).....	7
Detalhamento técnico do projeto.....	8
Figura 1 – Composição estrutural e identificação de padrões em credenciais.....	8
Figura 2 – Impacto crítico e tempo estimado de quebra por força bruta.....	8
Figura 3 – Interface do Painel Interativo de Conscientização.....	9
ENCERRAMENTO DO PROJETO.....	10
Relato Coletivo:.....	10
Figura 4 – Linha do tempo dos grandes vazamentos de dados globais.....	10
Figura 5 – Análise comparativa regional: Brasil versus Mundo.....	11
Avaliação de reação da parte interessada.....	11
Relato de Experiência Individual.....	12
Eduardo Hennes Gombrade.....	12
Leandro Schiavo de Oliveira.....	12
João Victor Romagnoli Vendito.....	13

DIAGNÓSTICO E TEORIZAÇÃO

Identificação das partes interessadas e parceiros

A parte interessada engloba a comunidade acadêmica do Centro Universitário UniMetrocamp Wyden, incluindo estudantes, docentes e colaboradores, bem como pequenos empreendedores locais da região de Campinas e usuários comuns de internet. Trata-se de um público que utiliza serviços digitais de forma massiva e diária, mas que, frequentemente, carece de letramento formal e técnico sobre cibersegurança e gestão adequada de credenciais.

Problemática e/ou problemas identificados

O principal problema identificado reside na fragilidade comportamental e técnica na criação e gestão de senhas por parte dos usuários. Observa-se a adoção sistêmica de padrões previsíveis — como datas de nascimento, sequências de teclado e palavras de dicionário —, o reaproveitamento da mesma credencial em múltiplos serviços corporativos e pessoais, e a baixa adesão à Autenticação em Dois Fatores (2FA). Tais práticas tornam os usuários altamente vulneráveis a vazamentos em massa (Data Breaches) e ataques de força bruta (Brute Force).

Justificativa

A aplicação de técnicas avançadas de Big Data, Ciência de Dados e programação em linguagem Python possibilita o processamento de milhões de registros oriundos de vazamentos reais para a extração de padrões matemáticos e comportamentais. Transformar essa volumetria de dados complexos em painéis interativos (Dashboards) e visualizações gráficas permite traduzir o risco tecnológico em conhecimento tangível e acessível. Dessa forma, o projeto atende à demanda sócio comunitária por letramento digital, agregando valor tanto à formação dos discentes de Análise e Desenvolvimento de Sistemas quanto à segurança da comunidade participante.

Objetivos/resultados/efeitos a serem alcançados
(em relação ao problema identificado e sob a
perspectiva dos públicos envolvidos)

Os objetivos propostos para mitigação do problema identificado compreendem:

- A. Coletar, tratar e higienizar bases massivas de dados reais de vazamentos de credenciais (tais como os conjuntos de dados RockYou e repositórios do Kaggle).
- B. Desenvolver um algoritmo capaz de calcular matematicamente a entropia das senhas e estimar o tempo computacional necessário para a quebra via força bruta.
- C. Identificar padrões de Engenharia Social na elaboração de senhas, mediante o uso de Processamento de Linguagem Natural (NLP) e Expressões Regulares (Regex).
- D. Desenvolver uma aplicação interativa que conscientize a comunidade, demonstrando de forma visual e em tempo real as vulnerabilidades de senhas de uso cotidiano.

Referencial teórico (subsídio teórico para
propositura de ações da extensão)

O projeto encontra embasamento nos pilares de Big Data volume, velocidade e variedade, adotando arquiteturas de dados otimizadas, como o formato Apache Parquet, que permite leitura colunar de alta performance. No âmbito da Segurança da Informação, o estudo fundamenta-se na Teoria da Informação e na Entropia de Shannon (1948), adaptada para ambientes criptográficos por meio da equação $E = L * \log_2(R)$, em que a robustez de uma credencial é diretamente proporcional ao seu comprimento (L) e à variação do conjunto de caracteres (R). Adicionalmente, apoia-se nos preceitos da Engenharia Social (MITNICK, 2002), que elucidam a propensão humana em priorizar a memorização em detrimento da complexidade, viabilizando ataques de dicionário.

PLANEJAMENTO E

DESENVOLVIMENTO DO PROJETO

Plano de trabalho (usando ferramenta acordada com o docente)

O desenvolvimento foi estruturado sob metodologia ágil, dividido nas seguintes etapas incrementais:

Fase 1 (Extração): Configuração do ambiente virtual (Google Colab e VSCode), mapeamento de fontes e ingestão dos datasets brutos (Notebook 01).

Fase 2 (Transformação e Carga - ETL): Limpeza, eliminação de dados nulos, aplicação de regras de negócio (cálculos de entropia e Regex) e exportação para o formato .parquet (Notebook 02).

Fase 3 (Análise Exploratória - EDA): Geração de estatísticas descritivas e estruturação das visualizações gráficas iniciais utilizando a biblioteca Plotly (Notebook 03).

Fase 4 (Apresentação e Produto Final): Desenvolvimento da interface de usuário em formato de Dashboard utilizando o framework Streamlit e consolidação da documentação acadêmica.

Descrição da forma de envolvimento do público participante na formulação do projeto, seu desenvolvimento e avaliação, bem como as estratégias utilizadas pelo grupo para mobilizá-los.

A mobilização do público e seu envolvimento ocorrem de forma ativa e experiencial por meio da interação com a aplicação (Dashboard). Durante as demonstrações, os participantes são convidados a inserir senhas hipotéticas no sistema, recebendo um feedback instantâneo sobre a entropia, o tempo estimado de quebra e a indicação de vazamentos prévios (cruzamento de dados). Essa dinâmica promove reflexão imediata e mudança comportamental em relação à gestão de suas próprias credenciais corporativas e pessoais.

Grupo de trabalho (descrição da responsabilidade de cada membro)

- Eduardo Hennes Gombrade: Engenheiro de Dados e Desenvolvedor Backend. Responsável pela arquitetura do Pipeline ETL, higienização dos dados, otimização de processamento (PyArrow/Parquet) e implementação lógica dos algoritmos matemáticos e de NLP.
- João Victor Romagnoli Vendito: Cientista de Dados e Desenvolvedor Frontend. Responsável pela construção das visualizações interativas (Plotly) e pela interface do usuário, assegurando os princípios de UI/UX e Data Storytelling na aplicação Streamlit.
- Leandro Schiavo de Oliveira: Pesquisador, Analista de Documentação e Gestor de Projetos. Responsável pelo levantamento bibliográfico, construção do referencial teórico, redação da documentação extensionista e alinhamento do escopo tecnológico aos propósitos socioeducativos da UniMetrocamp.

Metas, critérios ou indicadores de avaliação do projeto

- Processamento eficiente de bases contendo milhares de registros sem interrupções por falta de memória (Out of Memory).
- Atribuição bem-sucedida de métricas de entropia e classificação de padrões humanos para 100% da base válida.
- Implantação de um Dashboard funcional contendo gráficos interativos que explicam a correlação entre o tamanho da senha e sua vulnerabilidade.


Recursos previstos

- Hardware: Estações de trabalho e computadores pessoais dos discentes.
- Ambiente de Desenvolvimento: Google Colaboratory, Visual Studio Code (VSCode) e versionamento via Git/GitHub.
- Linguagem e Bibliotecas: Python 3.10+, pandas, numpy, plotly, streamlit, pyarrow e expressões regulares (re).

Detalhamento técnico do projeto


A arquitetura do sistema seguiu um pipeline de engenharia de dados. As bases brutas extraídas em CSV foram submetidas ao Pandas para tratamento. Uma função built-in foi desenvolvida para calcular o logaritmo binário das senhas (Entropia). Visando a fluidez da aplicação final, os dados processados foram exportados com motor PyArrow, gerando arquivos Parquet.

Figura 1 – Composição estrutural e identificação de padrões em credenciais



Conforme ilustrado na Figura 1, a análise demonstrou a predominância do uso de apenas caracteres minúsculos, evidenciando o comportamento de risco. Para enfatizar a gravidade, calculou-se o tempo de quebra, apresentado a seguir.

Figura 2 – Impacto crítico e tempo estimado de quebra por força bruta



A Figura 2 corrobora o referencial teórico, demonstrando que a ausência de entropia resulta na possibilidade de quebra instantânea por hardwares modernos de ataque cibernético. A

UniMetrocamp - Wyden

CAMPUS Campinas-SP

culminância do projeto técnico se deu na compilação destes dados em um Dashboard desenvolvido em Streamlit.

Figura 3 – Interface do Painel Interativo de Conscientização



ENCERRAMENTO DO PROJETO

Relato Coletivo:

A consecução das atividades previstas no projeto alcançou êxito integral. Sob o prisma tecnológico, a transição do armazenamento em CSV para o formato Apache Parquet revelou-se um diferencial competitivo na arquitetura, reduzindo drasticamente o tempo de leitura (I/O) e atestando a aplicabilidade dos conceitos de Big Data ensinados na disciplina.

O artefato final, nomeado Senhas em Risco, consolidou-se como uma ferramenta de alta eficácia socioeducativa. Empiricamente, os dados evidenciaram que a maior vulnerabilidade na segurança da informação não reside em falhas sistêmicas, mas sim no fator humano.

Figura 4 – Linha do tempo dos grandes vazamentos de dados globais





Figura 5 – Análise comparativa regional: Brasil versus Mundo



A análise temporal (Figura 4) e geográfica (Figura 5) permitiu ao grupo concluir que a conscientização digital não é um aspecto isolado, sendo essencial a adoção mandatória de políticas de MFA (Multi-Factor Authentication) em ambientes corporativos e educacionais

Avaliação de reação da parte interessada

Realizar avaliação de reação com a parte interessada (ex: formulário, entrevista gravada em áudio/vídeo, depoimento em áudio/vídeo etc.), para que o efetivo atingimento dos objetivos sociocomunitários propostos fique evidente.

Avaliação de reação da parte interessada

A validação do projeto ocorreu mediante demonstrações práticas do Dashboard interativo para a comunidade participante. A reação observada foi de surpresa, especialmente quando os participantes testaram variações de suas próprias senhas e constataram a vulnerabilidade em tempo real. O feedback qualitativo demonstrou que a interface visual facilitou a compreensão de conceitos de criptografia (entropia) e ataques de força bruta. Grande parte do público relatou a intenção de modificar senhas corporativas e ativar a autenticação em dois fatores (2FA) logo após a experiência, comprovando o sucesso e o impacto direto da ação de letramento digital promovida por este projeto.

Relato de Experiência Individual

Eduardo Hennes Gombrade

Contextualização: Atuei no presente projeto como Engenheiro de Dados e Desenvolvedor Backend, sendo o responsável direto pela construção da arquitetura do Pipeline de dados e pela garantia da integridade das bases massivas utilizadas. Metodologia: As atividades foram vivenciadas primariamente no ambiente Google Colab, utilizando Python. Detalhei as etapas de extração (E), onde ingeri dados globais do Kaggle e do RockYou; transformação (T), codificando as regras matemáticas de entropia e as Regex para identificação de padrões humanos; e carga (L), exportando os volumes para o formato .parquet. Resultados e Discussão: A expectativa de manipular Big Data foi plenamente atendida e, de certo modo, superada. Foi desafiador otimizar o processamento de milhões de strings sem esgotar a memória RAM do ambiente. Constatar que ferramentas básicas da engenharia de dados podem revelar vulnerabilidades de bilhões de pessoas em segundos resultou em um grande senso de responsabilidade técnica. Reflexão Aprofundada: A teoria estudada sobre otimização colunar convergiu com a prática. A experiência validou que um código mal estruturado é o maior gargalo na Ciência de Dados, e que o formato do dado (CSV vs Parquet) altera toda a viabilidade de uma aplicação web (Dashboard). Considerações Finais: Como perspectiva futura, recomendo a integração desta aplicação a uma API de Streaming de dados (como o Kafka), permitindo a ingestão em tempo real de novos Data Breaches, mantendo a base da UniMetrocamp eternamente atualizada.

João Victor Romagnoli Vendito

Contextualização: Minha participação centrou-se no papel de Cientista de Dados focado na visualização gráfica (Frontend), tendo a responsabilidade de tornar a massa de dados processada acessível e compreensível ao público-alvo. Metodologia: Recebendo os dados em Parquet do Backend, utilizei o framework Plotly para construção dos gráficos. A experiência se deu na codificação em ambiente local, culminando no desenvolvimento da interface via Streamlit. A abordagem focou na aplicação de um tema escuro e elementos visuais de alerta (vermelho para risco, verde para seguro) inerentes à cibersegurança. Resultados e Discussão: O maior desafio superado foi a implementação do Data Storytelling. Não bastava gerar um gráfico; era preciso que ele gerasse impacto. Senti imensa satisfação ao ver a interface rodando de maneira fluida. A facilidade do Streamlit em converter rotinas Python em uma aplicação Web superou minhas expectativas. Reflexão Aprofundada: Compreendi, de forma tácita, que o processo analítico é incompleto sem uma camada de apresentação. A teoria da Experiência do Usuário (UX) aplicada a dados provou-se fundamental; o público demonstrou maior retenção da informação através de recursos visuais dinâmicos. Considerações Finais: Para evolução deste trabalho, sugere-se o deploy

(hospedagem) do Dashboard na nuvem (Streamlit Community Cloud ou AWS EC2), disponibilizando a ferramenta via link público para campanhas de letramento digital em escolas da rede pública da região metropolitana de Campinas.

Leandro Schiavo de Oliveira

Contextualização: Inseri-me no projeto assumindo a Gestão da Documentação e a Pesquisa Acadêmica, exercendo a função de traduzir o rigor técnico dos códigos em uma linguagem formal e embasada, voltada à extensão universitária. Metodologia: O desenvolvimento da

documentação ocorreu em paralelo às Sprints de código. Utilizei técnicas de pesquisa bibliográfica para fundamentar o cálculo de entropia e os conceitos de vulnerabilidade. A experiência demandou forte comunicação interativa com os desenvolvedores (Eduardo e Leandro) para compreender o escopo da extração de dados e dos outputs visuais gerados. Resultados e Discussão: A integração dos resultados técnicos ao texto acadêmico foi a etapa mais recompensadora. Ao analisar os gráficos elaborados pela equipe, tornou-se claro o abismo entre o avanço tecnológico dos invasores e a inocência digital dos usuários comuns. Como aprendizado, consolidei minha capacidade de gestão ágil e estruturação lógica de projetos acadêmicos e corporativos. Reflexão Aprofundada: Contrastando a vivência com a teoria de extensão, notei que o projeto de fato age sobre uma demanda sociocomunitária real. A segurança digital deixou de ser um conceito abstrato das aulas de redes para se tornar um painel visual preventivo. Considerações Finais: Propõe-se a continuidade do projeto através de parcerias institucionais, transformando os relatórios aqui gerados em uma cartilha de boas práticas (Whitepaper). Além disso, o próprio software pode ser patentado ou oferecido de forma gratuita para auxiliar a TI da IES em campanhas internas de phishing e troca de credenciais.

(Eduardo e João)

CONTATOS

Eduardo Hennes Gombrade

Matrícula: 202502251971

Contato: 202502251971@alunos.unimetrocamp.edu.br

João Victor Romagnoli Vendito

Matrícula: 202402531425

Contato: 202402531425@alunos.unimetrocamp.edu.br

Leandro Schiavo de Oliveira

Matrícula: 202402531271

Contato: 202402531271@alunos.unimetrocamp.edu.br

Orientador: Prof. Leonardo Ramos de Oliveira