

UNIMETROCAMP WYDEN · 2026

Senhas em Risco

Big Data e Segurança Digital

Como técnicas de Big Data e Ciência de Dados podem identificar padrões inseguros na criação de senhas — e conscientizar usuários sobre riscos reais de segurança digital.



Made with GAMMA

O PROBLEMA

Por Que Senhas Ainda Falham?

O comportamento humano é a principal vulnerabilidade em segurança digital. Usuários criam senhas previsíveis, reutilizam credenciais em múltiplos serviços e possuem baixa adesão à autenticação em dois fatores (2FA), aumentando a exposição a vazamentos de dados e ataques de força bruta. O projeto **Senhas em Risco** foi desenvolvido para analisar esses padrões em grandes volumes de dados reais e conscientizar usuários sobre os riscos envolvidos.

Senhas Previsíveis

Padrões comuns como "123456", "senha" e variações com nomes pessoais continuam predominando nas bases vazadas, facilitando ataques de dicionário e engenharia social.

Reutilização de Credenciais

Um único vazamento compromete múltiplas contas quando o usuário repete a mesma senha em diferentes serviços, amplificando o impacto de cada incidente.

Baixa Adesão ao 2FA

A autenticação em dois fatores ainda é subutilizada pela maioria dos usuários, deixando contas desprotegidas mesmo com senhas moderadamente fortes.

O Impacto dos Vazamentos de Dados

Data Breaches: Uma Crise Global

Incidentes de segurança cibernética crescem em escala e frequência. Grandes plataformas, redes sociais e serviços financeiros já tiveram bilhões de credenciais expostas — muitas vezes sem que os usuários sequer soubessem.

O projeto analisa dados de vazamentos reais entre **2004 e 2024**, revelando padrões comportamentais que tornam senhas vulneráveis a ataques de força bruta e engenharia social.


O Que os Dados Revelam

- Senhas simples continuam **predominando** mesmo após anos de alertas públicos
- O **fator humano** é a principal vulnerabilidade — não a tecnologia
- Visualizar os dados **aumenta a percepção de risco** nos usuários
- Formatos otimizados como **Parquet** melhoram performance analítica

OBJETIVO


O Que o Projeto Faz

O **Senhas em Risco** é uma aplicação de análise de Big Data voltada para a conscientização em Segurança da Informação. O projeto processa e analisa grandes volumes de dados de vazamentos reais (Data Breaches) para identificar vulnerabilidades matemáticas e comportamentais na criação de senhas. O produto final é um Dashboard Interativo que traduz métricas complexas em visualizações acessíveis.



Analisa Bases Vazadas

Processa grandes volumes de senhas reais de data breaches para identificar padrões comportamentais e matemáticos de vulnerabilidade.



Calcula Entropia

Demonstra a força matemática de uma senha e estima o tempo necessário para quebra via ataques de força bruta.



Dashboard Interativo

Traduz métricas complexas de criptografia e engenharia social em visualizações acessíveis com **Plotly** e **Streamlit**.



Identifica Padrões Humanos

Usa NLP e Expressões Regulares para detectar padrões de engenharia social nas senhas mais utilizadas no Brasil e no mundo.

Como o Sistema Funciona

O sistema foi desenvolvido sob uma arquitetura de dados robusta, com um pipeline ETL completo que transforma dados brutos de vazamentos em insights visuais de conscientização. Cada etapa foi otimizada para processar grandes volumes com alta performance.



O uso do formato colunar **Apache Parquet** (via **PyArrow**) garante alta velocidade de leitura (I/O) no processamento analítico. O motor **NLP/Regex** identifica padrões humanos de engenharia social nas senhas. Todo o pipeline foi construído em **Python**, com **Pandas** e **NumPy** para extração, limpeza e enriquecimento dos dados.

Arquitetura e Stack Tecnológico

Stack Principal



Python

Linguagem central do projeto, integrando todas as camadas do pipeline.



Pandas & NumPy

Extração, limpeza e enriquecimento de dados no pipeline ETL.



PyArrow & Apache Parquet

Processamento otimizado com formato colunar para alta velocidade de I/O.



Plotly

Geração de gráficos interativos e Data Storytelling.



Streamlit

Deploy do Dashboard interativo como aplicação web.

Motor de Análise

NLP + Regex

Algoritmos em Python para identificar padrões humanos (Engenharia Social) em senhas, detectando sequências previsíveis e comportamentos de risco.

Entropia

Cálculo matemático da força de uma senha, demonstrando o tempo estimado para quebra via ataques de força bruta.




Projeto desenvolvido para a disciplina de **Tópicos de Big Data em Python** — UniMetrocamp Wyden, 2026.

FIGURA 1 — DIAGNÓSTICO

Composição das Senhas por Tipo de Caractere

O gráfico de barras duplas revela a **composição estrutural das credenciais** analisadas. O eixo horizontal esquerdo mede o percentual de senhas contendo cada tipo de caractere (0–100%), enquanto o eixo vertical direito quantifica a distribuição de senhas por quantidade de tipos utilizados (1 a 4 tipos). Os dados expõem uma vulnerabilidade crítica: a esmagadora maioria dos usuários ignora completamente símbolos e letras maiúsculas.



Análise dos Dados


Tipo de Caractere	Percentual (%)	Qtd. Senhas
Símbolos	2,8% (18.771)	0,1%
Maiúsculas	13,0% (87.063)	87,4%
Números	99,2% (664.189)	11,8%
Minúsculas	98,1% (657.032)	0,7%

A predominância de minúsculas (98,1%) e números (99,2%) contrasta com o uso quase inexistente de símbolos (2,8%). Isso evidencia o comportamento de risco sistêmico: usuários priorizam a memorização em detrimento da complexidade, viabilizando ataques de dicionário e força bruta (MITNICK, 2002).

⚠ Conclusão: A ausência de diversidade de caracteres reduz drasticamente a entropia das senhas, tornando-as quebráveis em segundos por hardwares modernos de ataque cibernético.

Distribuição do Tempo Estimado de Quebra por Força Bruta

Com base na **Hive Systems Password Table 2024**, este gráfico mapeia quantas senhas do dataset podem ser quebradas em cada faixa de tempo. A distribuição evidencia que a ausência de entropia não é uma exceção — é a regra. A maioria das credenciais analisadas oferece proteção praticamente nula contra atacantes equipados com hardware moderno.



Distribuição por Faixa de Tempo

Tempo Estimado	% de Senhas
Instantâneo	0,0%
Segundos	5,9%
Horas	24,2%
Semanas	42,1%
Anos	12,3%
Séculos	15,4%

Segundo a **Entropia de Shannon (1948)**, adaptada para ambientes criptográficos pela equação $E = L \times \log_2(R)$, a robustez é proporcional ao comprimento (L) e à variação de caracteres (R). A ausência de entropia resulta em quebra quase instantânea.

66,3% das senhas são quebradas em menos de uma semana. Apenas 15,4% resistiriam por séculos — e isso depende exclusivamente de comprimento e diversidade de caracteres.

FIGURA 3 — PRODUTO FINAL

Interface do Painel Interativo de Conscientização

O Dashboard desenvolvido em **Streamlit** consolida toda a análise em uma interface visual acessível. Os participantes inserem senhas hipotéticas e recebem feedback instantâneo sobre entropia, tempo de quebra e histórico de vazamentos. A mobilização ocorre de forma ativa e experiencial, promovendo reflexão imediata e mudança comportamental.



Componentes do Dashboard

Força das Semanas

Gráfico de rosca mostrando distribuição de níveis de conscientização: Alta (25%), Média (50%), Baixa (15%) e Nenhuma (10%).

Tempo por Trimestre

Barras coloridas representando o tempo de interação com a plataforma ao longo de 5 trimestres.

Incidências por Ano

Linha temporal de incidentes reportados (Jan-Dez), evidenciando a sazonalidade dos ataques.

Top 10 Incidentes

Ranking horizontal dos tipos mais comuns de incidentes de segurança, com codificação por cores de risco.

✔ **Impacto observado:** Grande parte do público relatou intenção de modificar senhas corporativas e ativar 2FA logo após a experiência, comprovando o sucesso da ação de letramento digital.

Análise Temporal e Geográfica dos Vazamentos Globais

FIGURA 4 — LINHA DO TEMPO (2004–2024)


Grandes Vazamentos de Dados Globais



O gráfico combinado (barras + linha) mapeia o número de incidentes (eixo Y esquerdo, 0–30) e o total de afetados em milhões (eixo Y direito, 0M–4000M). Picos notórios: **2013** (3,5 bilhões afetados), **2019** (3,8 bilhões) e **2018** (1,5 bilhão). A tendência confirma que ataques se tornam mais frequentes e devastadores ao longo do tempo.

FIGURA 5 — NORDPASS 2024

Top 15 Senhas Mais Comuns no Mundo



Todas as 15 senhas listadas são quebradas em **menos de 1 segundo**. A mais utilizada, "**123456**", afeta ~4 milhões de usuários. "password" (~3,8M) e "123456789" (~3,2M) completam o pódio da negligência digital. Fonte: *NordPass Most Common Passwords 2024*.



Conclusão coletiva: A conscientização digital não é aspecto isolado — é essencial a adoção mandatória de políticas de **MFA (Autenticação Multifator)** em ambientes corporativos e educacionais.

Equipe do Projeto

Eduardo Hennes Gombrade

Eng. de Dados / Backend — Pipeline ETL, Parquet, NLP

202502251971@alunos.unimetrocamp.edu.br

João Victor Romagnoli Vendito

Cientista de Dados / Frontend — Plotly, Streamlit, UI/UX

202402531425@alunos.unimetrocamp.edu.br

Leandro Schiavo de Oliveira

Pesquisador / Gestor — Documentação, Referencial Teórico

202402531271@alunos.unimetrocamp.edu.br

Orientador: Prof. Leonardo Ramos de Oliveira

Impacto Social, Equipe e Próximos Passos

Este projeto possui finalidade exclusivamente **acadêmica e educacional** (Extensão Universitária). Desenvolvido na disciplina de Tópicos de Big Data em Python da UniMetrocamp Wyden (2026), o projeto demonstra como a análise de dados pode ser aplicada para conscientização em segurança digital.

Eduardo Gombrade

Análise e Desenvolvimento — Pipeline ETL e Backend

João Vendito

Dashboard e Visualizações — Streamlit / Plotly

Leandro Schiavo

Documentação — Pesquisa Acadêmica e Roteiro

Lições Aprendidas

- Big Data aplicado à segurança é uma ferramenta poderosa de conscientização
- Visualização de dados transforma métricas complexas em mensagens acessíveis
- Otimização de formatos (Parquet) é essencial para performance em grandes volumes

Próximos Passos

- Ampliar a base de dados com novos vazamentos públicos
- Integrar verificação em tempo real de senhas no dashboard
- Publicar artigos acadêmicos sobre os padrões identificados
- Expandir a análise para outros idiomas e regiões

Perguntas? O código-fonte está disponível no repositório público do GitHub: [eduardo-hgombrade/projeto-seguranca-senhas](https://github.com/eduardo-hgombrade/projeto-seguranca-senhas)